

Práctica 1.1 — Probabilidad y Estadística

Análisis de la evolución poblacional mundial

Objetivo

Utilizar un conjunto de datos real para comprobar el funcionamiento del entorno de análisis de datos y aplicar medidas estadísticas descriptivas básicas con Pandas y NumPy.

Actividad 1 — Identificación de la fuente

Para esta actividad se consultaron los archivos `data/raw/annual-population-growth/annual-population-growth.readme.md` y `annual-population-growth.metadata.json`. Se trabajará únicamente con los datos históricos de cambio anual de población (1951–2023).

Fuente y cita

Los datos utilizados provienen de **Our World in Data (OWID)**. La fuente original es **United Nations, World Population Prospects (2024)**.

UN, World Population Prospects (2024) – processed by Our World in Data.
“Annual change in population – UN WPP” [dataset]. United Nations, “World Population Prospects”; United Nations, “World Population Prospects - Interim Update” [original data].

Respuestas

¿Quién produjo originalmente los datos? Las Naciones Unidas, mediante *World Population Prospects (2024)*.

¿Qué organización los procesa para su utilización en Our World in Data? Our World in Data (OWID).

¿Qué representa la variable que analizarás? La variable representa el cambio anual neto de población, calculado como la diferencia entre la población al 1 de julio de dos años consecutivos. Incluye conjuntamente el efecto de nacimientos, defunciones y migración; su unidad es personas.

Actividad 2 — Carga y exploración de datos

En esta actividad se carga el archivo de cambio anual de población y se revisa la estructura del DataFrame. Aunque el conjunto incluye proyecciones, en las actividades posteriores se utilizarán únicamente los registros históricos.

```
In [1]: from pathlib import Path

import numpy as np
import pandas as pd
```

```
In [4]: path = Path("../data/raw/annual-population-growth/annual-population-growth.csv")

df = pd.read_csv(path)
df.head()
```

```
Out[4]:
```

	Entity	Code	Year	Annual change in population	Annual population change (Projected)
0	Afghanistan	AFG	1951	103163.0	NaN
1	Afghanistan	AFG	1952	108441.0	NaN
2	Afghanistan	AFG	1953	108919.0	NaN
3	Afghanistan	AFG	1954	111251.0	NaN
4	Afghanistan	AFG	1955	119027.0	NaN

Exploración de la estructura

Las siguientes celdas muestran las primeras filas, dimensiones, columnas, tipos de datos y estadísticas descriptivas solicitadas.

```
In [3]: print("Dimensiones (filas, columnas):", df.shape)
print("\nNombres de columnas:")
print(df.columns.tolist())
print("\nTipos de datos:")
print(df.dtypes)

df.describe()
```

```
Dimensiones (filas, columnas): (38400, 5)
```

```
Nombres de columnas:
```

```
['Entity', 'Code', 'Year', 'Annual change in population', 'Annual population change (Projected)']
```

```
Tipos de datos:
```

```
Entity          str
Code            str
Year            int64
Annual change in population    float64
Annual population change (Projected)  float64
dtype: object
```

	Year	Annual change in population	Annual population change (Projected)
count	38400.000000	1.868800e+04	1.971200e+04
mean	2025.500000	2.063019e+06	8.375481e+05
std	43.300872	9.440859e+06	5.816745e+06
min	1951.000000	-3.315935e+06	-2.291035e+07
25%	1988.000000	1.781000e+03	-9.742750e+03
50%	2025.500000	4.689800e+04	9.350000e+01
75%	2063.000000	3.021128e+05	1.411160e+05
max	2100.000000	9.337137e+07	7.206736e+07

```
In [ ]: print("Valores faltantes por columna:")
print(df.isnull().sum())
print("\nNúmero de entidades diferentes:", df["Entity"].nunique())
```

Respuestas

¿Cuántas filas y columnas tiene el dataset? \n El dataset tiene **38,400 filas** y **5 columnas**.

¿Qué tipo de datos contiene la variable Year ? \n Al cargar el archivo con Pandas, Year tiene tipo entero (int64).

¿Existen valores faltantes? \n Sí. Code tiene 1,200 valores faltantes. Las dos columnas de cambio poblacional también presentan valores faltantes porque una contiene los datos históricos y la otra las proyecciones; se utilizará la columna histórica en la siguiente actividad.

¿Cuántas entidades diferentes contiene el dataset? \n El dataset contiene **256 entidades** diferentes.

```
In [ ]:
```

```
In [6]: ## Extracción de entidad y cambio anual de población

entity_annual_change = (
    df[["Entity", "Annual change in population"]]
    .dropna(subset=["Annual change in population"])
    .reset_index(drop=True)
)

entity_annual_change.head()
```

Out[6]:

	Entity	Annual change in population
0	Afghanistan	103163.0
1	Afghanistan	108441.0
2	Afghanistan	108919.0
3	Afghanistan	111251.0
4	Afghanistan	119027.0

In [7]: `df["Entity"].unique()`

Out[7]: <StringArray>
['Afghanistan', 'Africa (UN)', 'Albania',
 'Algeria', 'American Samoa', 'Americas (UN)',
 'Andorra', 'Angola', 'Anguilla',
 'Antigua and Barbuda',
 ...
 'Vanuatu', 'Vatican', 'Venezuela',
 'Vietnam', 'Wallis and Futuna', 'Western Sahara',
 'World', 'Yemen', 'Zambia',
 'Zimbabwe']
Length: 256, dtype: str

In [14]: `belgium_1983_2021 = (
 df.loc[
 (df["Entity"] == "Belgium") & df["Year"].between(1983, 2021),
 ["Entity", "Year", "Annual change in population"]
]
 .sort_values("Year")
)`

`print("Belgium: annual population change (1983-2021)")
display(belgium_1983_2021)`

`annual_change = "Annual change in population"
min_row = belgium_1983_2021.loc[belgium_1983_2021[annual_change].idxmin()]
max_row = belgium_1983_2021.loc[belgium_1983_2021[annual_change].idxmax()]`

`summary = pd.DataFrame({
 "Statistic": ["Minimum", "Maximum"],
 "Year": [int(min_row["Year"]), int(max_row["Year"])],
 annual_change: [min_row[annual_change], max_row[annual_change]]
})`

`print("Minimum and maximum annual change, including the year:")
display(summary)`

`print("Standard statistics for the 1983-2021 range:")
display(belgium_1983_2021[annual_change].describe().to_frame(annual_change))`

Belgium: annual population change (1983-2021)

	Entity	Year	Annual change in population
3332	Belgium	1983	6807.0
3333	Belgium	1984	5450.0
3334	Belgium	1985	5752.0
3335	Belgium	1986	6643.0
3336	Belgium	1987	12169.0
3337	Belgium	1988	17416.0
3338	Belgium	1989	20009.0
3339	Belgium	1990	24393.0
3340	Belgium	1991	37994.0
3341	Belgium	1992	47026.0
3342	Belgium	1993	38944.0
3343	Belgium	1994	31073.0
3344	Belgium	1995	21259.0
3345	Belgium	1996	19708.0
3346	Belgium	1997	24493.0
3347	Belgium	1998	21720.0
3348	Belgium	1999	23496.0
3349	Belgium	2000	25038.0
3350	Belgium	2001	35286.0
3351	Belgium	2002	45970.0
3352	Belgium	2003	43287.0
3353	Belgium	2004	45036.0
3354	Belgium	2005	57585.0
3355	Belgium	2006	69562.0
3356	Belgium	2007	77043.0
3357	Belgium	2008	84223.0
3358	Belgium	2009	103225.0
3359	Belgium	2010	123683.0
3360	Belgium	2011	102005.0
3361	Belgium	2012	68898.0

	Entity	Year	Annual change in population
3362	Belgium	2013	52755.0
3363	Belgium	2014	49836.0
3364	Belgium	2015	65219.0
3365	Belgium	2016	57375.0
3366	Belgium	2017	43876.0
3367	Belgium	2018	52025.0
3368	Belgium	2019	62015.0
3369	Belgium	2020	49479.0
3370	Belgium	2021	30741.0

Minimum and maximum annual change, including the year:

	Statistic	Year	Annual change in population
0	Minimum	1984	5450.0
1	Maximum	2010	123683.0

Standard statistics for the 1983–2021 range:

	Annual change in population
count	39.000000
mean	43808.051282
std	28197.423435
min	5450.000000
25%	22608.000000
50%	43287.000000
75%	57480.000000
max	123683.000000